

深度学习个人笔记

Amamiyaren

my own deep learning notes

更新：2024 年 5 月 17 日

1 多元线性回归

1.1 基本形式

线性模型试图学得一个通过属性的线性组合来预测的函数，基本形式如下：

$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \cdots + w_dx_d + b \quad (1.1)$$

向量形式如下：

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + \mathbf{b} \quad (1.2)$$

1.2 一元情形

一般采用最小二乘法确定模型参数,一元情形推导如下：

$$\begin{aligned} (w^*, b^*) &= \arg \min_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 \\ &= \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2 \end{aligned} \quad (1.3)$$

我们令 $E_{(w,b)} = \arg \min_{(w,b)} \sum_{i=1}^m (y_i - wx_i - b)^2$ ，等式两边同时对 w 和 b 求导有：

$$\frac{\partial E_{(w,b)}}{\partial b} = 2 \left(mb - \sum_{i=1}^m (y_i - wx_i) \right) \quad (1.4)$$

$$\begin{aligned} \frac{\partial E_{(w,b)}}{\partial w} &= \sum_{i=1}^m 2(y_i - wx_i - b)(-x_i) \\ &= 2 \left(w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b)x_i \right) \end{aligned} \quad (1.5)$$

然后令式(1.4)和(1.5)为零得到：

$$\begin{aligned} b &= \frac{1}{m} \sum_{i=1}^m y_i - wx_i \\ &= \bar{y} - w\bar{x} \end{aligned} \quad (1.6)$$

$$w \sum_{i=1}^m x_i^2 = \sum_{i=1}^m (y_i - b)x_i \quad (1.7)$$

将(1.6)带入(1.7)得到：

$$\begin{aligned} w \sum_{i=1}^m x_i^2 &= \sum_{i=1}^m (y_i x_i) - \sum_{i=1}^m (\bar{y} - w\bar{x})x_i \\ &= \sum_{i=1}^m y_i x_i - \bar{y} \sum_{i=1}^m x_i + w\bar{x} \sum_{i=1}^m x_i \end{aligned} \quad (1.8)$$

对(1.8)式进行化简，最终可得：

$$w = \frac{\sum_{i=1}^m y_i x_i - \bar{y} \sum_{i=1}^m x_i}{\sum_{i=1}^m x_i^2 - \sum_{i=1}^m \bar{x} x_i} \quad (1.9)$$

又由于 $\bar{y} \sum_{i=1}^m x_i = \frac{1}{m} \sum_{i=1}^m y_i \cdot \sum_{i=1}^m x_i = \bar{x} \sum_{i=1}^m y_i$ 和 $\bar{x} \sum_{i=1}^m y_i = \frac{1}{m} \sum_{i=1}^m x_i \sum_{i=1}^m y_i = \frac{1}{m} \left(\sum_{i=1}^m x_i \right)^2$ 将这两个式子带入(1.9)式进行进一步化简得到:

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \left(\sum_{i=1}^m x_i \right)^2} \quad (1.10)$$

1.2.1 一元情形的矩阵形式

由于 python 中累加形式只能使用for循环进行迭代, 运行效率比较低, 如果将(1.20)式转化为矩阵形式可以使用numpy等第三方库对其矩阵运算进行加速, 公式推导如下:

$$\bar{y} \sum_{i=1}^m x_i \bar{x} \sum_{i=1}^m y_i = \sum_{i=1}^m \bar{y} x_i = \sum_{i=1}^m \bar{x} y_i = m \bar{x} \bar{y} = \sum_{i=1}^m \bar{x} \bar{y} \quad (1.11)$$

$$\sum_{i=1}^m x_i \bar{x} = \bar{x} \sum_{i=1}^m x_i = \bar{x} \cdot m \cdot \frac{1}{m} \sum_{i=1}^m x_i = m \bar{x}^2 = \sum_{i=1}^m \bar{x}^2 \quad (1.12)$$

将式(1.21)和式(1.22)带入式(1.9)可以得到:

$$\begin{aligned} w &= \frac{\sum_{i=1}^m (y_i x_i - y_i \bar{x} - x_i \bar{y} + \bar{x} \bar{y})}{\sum_{i=1}^m (x_i^2 - \bar{x} x_i - \bar{x} x_i + \bar{x}^2)} \\ &= \frac{\sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^m (x_i - \bar{x})^2} \end{aligned} \quad (1.13)$$

记 $x = (x_1; x_2 \dots x_m)$, $x_d = (x_1 - \bar{x}; x_2 - \bar{x} \dots x_m - \bar{x})$, y_d 同 x_d , 再由向量内积的定义可以得到:

$$w = \frac{x_d^T y_d}{x_d^T x_d} \quad (1.14)$$

1.2.2 多元

多元的情形可由一元的情形举一反三推导出，如下：

$$\begin{aligned}
 w^* &= \arg \min_{(\hat{w})} \sum_{i=1}^m (y_i - \hat{w}^T x_i)^2 \\
 &= \arg \min_{(\hat{w})} \sum_{i=1}^m (y_i - x_i^T \hat{w})^2 \\
 &= \arg \min_{(\hat{w})} \begin{bmatrix} y_1 - x_1^T \hat{w} \\ \vdots \\ y_m - x_m^T \hat{w} \end{bmatrix} \cdot \begin{bmatrix} y_1 - x_1^T \hat{w} \\ \vdots \\ y_m - x_m^T \hat{w} \end{bmatrix} \quad (1.15)
 \end{aligned}$$

其中：

$$\begin{aligned}
 \begin{bmatrix} y_1 - x_1^T \hat{w} \\ y_2 - x_2^T \hat{w} \\ \vdots \\ y_m - x_m^T \hat{w} \end{bmatrix} &= \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} - \begin{bmatrix} x_1^T \hat{w} \\ x_2^T \hat{w} \\ \vdots \\ x_m^T \hat{w} \end{bmatrix} \\
 &= y - \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_m^T \end{bmatrix} \cdot \hat{w} \\
 &= y - X \hat{w} \quad (1.16)
 \end{aligned}$$

所以：

$$\hat{w}^* = \arg \min_{(\hat{w})} (y - X \hat{w})^T (y - X \hat{w}) \quad (1.17)$$

现引入两个定理对 \hat{w} 的最优解做进一步推导。

1.2.3 w 预测值的求解

*Def*_{1.28}：设 $D \subset R^n$ 为非空开凸集 $f(x)$ 是定义在 D 上的实值函数，且 $f(x)$ 在 D 上二阶连续可微，若 $f(x)$ 的Hession矩阵 $\nabla^2 f(x)$ 在 D 上半正定则 $f(x)$ 是 D 上

的凸函数，若 $\nabla^2 f(x)$ 在 D 上正定则 $f(x)$ 为 D 上的严格凸函数。 *Def_{1.29}*：若 $f(x)$ 为凸函数且 $f(x)$ 一阶连续可微则 x^* 是全局最优解的充要条件为其梯度等于零向量即：

$$\nabla f(x^*) = \mathbf{0}$$

$$\begin{aligned} E_{\hat{w}} &= (y - X\hat{w})^T (y - X\hat{w}) \\ &= y^T y - y^T X\hat{w} - \hat{w}^T X^T y + \hat{w}^T X^T X \hat{w} \end{aligned} \quad (1.18)$$

$$\begin{aligned} \frac{\partial E_{\hat{w}}}{\partial \hat{w}} &= 0 - X^T y - X^T y + (X^T X + X^T X) \hat{w} \\ &= 2X^T (X\hat{w} - y) \end{aligned} \quad (1.19)$$

由式(1.31)再对 \hat{w}^T 求偏导可以得到 $E_{\hat{w}}$ Hession矩阵的表达式，如下：

$$\begin{aligned} \nabla^2 E_{\hat{w}} &= \frac{\partial}{\partial w^T} \left(\frac{\partial E_{\hat{w}}}{\partial w} \right) \\ &= 2X^T X \end{aligned} \quad (1.20)$$

由*Def_{1.28}*, *Def_{1.29}*当 $X^T X$ 为正定矩阵时，令其梯度为零向量可解得方程的全局最优解即：

$$\hat{w}^* = (X^T X)^{-1} X^T y \quad (1.21)$$